

毕业设计中期汇报

题目：基于大模型的软件工程文档内容结构化提取系统设计与实现

一、问题与价值

软件工程文档（SRS、API 文档、测试报告等）普遍以非结构化形式存储，传统提取手段（关键词匹配、正则、NLP 模型）在语义理解和复杂结构抽取上均存在明显局限。

大模型的优势在于语义级理解与结构化抽取，例如：

- 输入："系统应该允许管理员删除用户账户。"
- 输出：{ "module": "用户管理", "function": "删除用户", "type": "功能需求" }

项目核心价值：将非结构化软件工程文档转化为可检索、可复用的结构化数据，服务于AI编程、研发协作、知识沉淀与文档治理等场景。

二、系统架构

系统采用"解析 → 分类 → 提取 → 索引 → 问答"的轻量化分层架构：



技术栈：

层次	技术
后端	FastAPI + Tortoise-ORM + SQLite
解析	pymupdf4llm (PDF) 、 python-docx (DOCX)
提取	DashScope/Qwen (OpenAI-Compatible) + Pydantic
检索	FAISS + text-embedding-v4
前端	Vue 3 + Tailwind CSS



三、已完成工作

系统已实现完整 MVP 闭环，支持 **7 类** 软件工程文档的结构化提取与知识问答：

SRS 需求规格 / API 接口文档 / 系统设计说明书 / 测试计划 / 测试用例 / 测试报告 / 用户手册

核心能力：

- 多格式解析**：统一接入 PDF/DOCX/MD/TXT，输出标准化 Markdown 供后续处理
- 智能分类与结构化提取**：LLM 自动识别文档类型，结合预定义 Pydantic Schema 输出结构化 JSON
- 长文档分块处理**：超阈值文档自动分块调用、结果合并去重，具备三段降级容错机制
- 语义分块 (Chunker)**：识别段落/列表/表格/代码块，自动补切与合并，生成适合向量化的语义片段
- RAG 知识问答**：FAISS 向量召回 + LLM 生成答案，返回带评分引用，具备可解释性

后端已完成 7 个核心接口（上传、查询、删除、重建索引、问答），前端支持文档管理、问答交互与 JSON 结构展示。

四、下一步计划

优先级	任务	目的
高	评估 DeepSeek、Qwen 等模型的抽取表现，对比准确率与性价比	论文模型选型依据
高	系统对比多维 Prompt 策略（语言、粒度、角色设定、结构约束）对提取质量的影响	论文Prompt对比实验
高	收集软件工程文档数据集，测试长文档场景下系统稳定性	验证系统鲁棒性
中	LLM 调用改为异步，提升并发处理性能	系统性能优化
中	支持 URL 输入，抓取在线文档	扩展输入来源

